

Classificação de Lesões de Pele: Uma Abordagem Multimodal com Dados Tabulares e Imagens Dermatoscópicas

Mateus Siqueira Ruzene
Ciência da Computação – UFPR
mateus.ruzene@ufpr.br

Bruno Crestani
Ciência da Computação – UFPR
bruno.crestani@ufpr.br

Abstract

*Este documento descreve a proposta de projeto para a disciplina CII171 – Aprendizagem de Máquina (1/2026). Propomos a classificação de lesões de pele utilizando duas modalidades complementares de dados: (i) dados tabulares com metadados clínicos (sexo, idade, localização da lesão) e (ii) imagens dermatoscópicas do dataset **HAM10000** [8]. O objetivo é comparar e combinar métodos clássicos de aprendizagem de máquina com redes neurais convolucionais para diagnosticar automaticamente sete categorias de lesões, incluindo melanoma.*

1. Enunciado do Problema e Aplicação

O câncer de pele é o tipo de câncer mais prevalente mundialmente, representando cerca de um terço de todos os diagnósticos de câncer [4]. O diagnóstico precoce é decisivo para o prognóstico do paciente, porém a análise dermatoscópica de lesões exige alta especialização médica, tornando a triagem manual cara e inacessível em regiões com escassez de dermatologistas.

Os principais desafios da aplicação incluem o **forte desbalanceamento de classes** (melanoma representa menos de 12% das amostras), a **alta variabilidade intraclasse** das lesões e a necessidade de interpretar conjuntamente atributos clínicos e aparência visual. Espera-se que modelos multimodais superem classificadores unimodais, e que métodos de aumento de dados e re-amostragem mitiguem o impacto do desbalanceamento.

2. Seleção do Conjunto de Dados

Utilizaremos o **HAM10000** (*Human Against Machine with 10000 training images*) [7, 8], disponibilizado pelo ISIC Archive e acessível via Kaggle [6]. O dataset contém:

- **10.015 imagens** dermatoscópicas coloridas de lesões, com resolução de 600×450 pixels (formato JPEG).

- **Metadados tabulares** por lesão: diagnóstico (*label*), idade do paciente, sexo biológico, localização anatômica e método de confirmação do diagnóstico.
- **7 classes**: *nv* (nevo melanocítico), *mel* (melanoma), *bkl* (queratose benigna), *bcc* (carcinoma basocelular), *akiec* (ceratose actínica), *vasc* (lesão vascular), *df* (dermatofibroma).

O dataset respeita o limite de 50.000 exemplos exigido.

3. Metodologia Possível

Para os **dados tabulares**, serão avaliados classificadores clássicos: Regressão Logística, *Random Forest* [1] e XGBoost [2], após pré-processamento (normalização, codificação de categorias e imputação de valores ausentes). Para as **imagens**, serão utilizadas redes convolucionais pré-treinadas (*transfer learning* com ResNet-50 [5]), com ajuste fino nas últimas camadas. Adicionalmente, será investigada a **fusão** de descritores de imagens com os metadados clínicos, por meio de concatenação de *embeddings* em uma rede híbrida.

O desbalanceamento de classes será tratado com *over-sampling* (SMOTE para dados tabulares) e aumento de dados (*data augmentation*) para imagens. As métricas de avaliação principais serão: acurácia balanceada, AUC-ROC *multiclasse*, F1-*macro* e matriz de confusão. Espera-se que o modelo multimodal atinja F1-*macro* superior a 0,75, alinhado com resultados reportados na literatura para o HAM10000 [3]. Os comparativos entre modelos permitirão identificar a contribuição relativa de cada modalidade, o que é relevante para cientistas e engenheiros que buscam soluções de triagem dermatológica em ambientes com recursos computacionais limitados.

References

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. 1
- [2] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. *ACM SIGKDD International Conference*

on *Knowledge Discovery and Data Mining*, pages 785–794, 2016. 1

- [3] Noel C. F. Codella, Veronica Rotemberg, Philipp Tschandl, M. Emre Celebi, Stephen Dusza, David Gutman, Brian Helba, Aadi Kalloo, Konstantinos Liopyris, Michael A. Marchetti, Harald Kittler, and Allan Halpern. Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the international skin imaging collaboration (ISIC). In *arXiv preprint arXiv:1902.03368*, 2019. 1
- [4] Andre Esteva, Brett Kuprel, Roberto A. Novoa, Justin Ko, Susan M. Swetter, Helen M. Blau, and Sebastian Thrun. Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639):115–118, 2017. 1
- [5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 770–778, 2016. 1
- [6] International Skin Imaging Collaboration. ISIC archive – skin lesion dataset. <https://www.isic-archive.com>, 2023. Accessed: March 2026. 1
- [7] Philipp Tschandl. HAM10000 – skin lesion dataset on Kaggle. <https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000>, 2018. Accessed: March 2026. 1
- [8] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5(1):180161, 2018. 1